

MVP - Data Engineering



Análise do Orçamento e da Concessão de Bolsas da CAPES entre 2013 e 2020

Aluna: Matheus Silva de Araujo Rodrigues

Email: ma_the285@hotmail.com

GitHub: https://github.com/mathe8silva/mvp_MatheusRodrigues

Discord: alucem

Sprint: Engenharia de Dados (40530010057_20260_01)

SUMÁRIO

SUMÁRIO

1. INTRODUÇÃO	4
2. OBJETIVO	5
3. CARGA DOS DADOS	5
3.1 Fonte dos dados	5
3.1.1 Dados orçamentários da CAPES	6
3.1.2 Dados orçamentários do MEC	7
3.1.3 Dados das Bolsas CAPES	7
3.1.4 Licença e utilização dos dados	8
3.2 Ambiente utilizado	8
3.3 Armazenamento dos arquivos no Databricks	8
4. PIPELINE DE DADOS	9
4.1 Preparação do ambiente	10
4.2 Camada Bronze	11
4.2.1 Ingestão dos dados	11
4.2.2 Leitura dos arquivos	12
4.2.3 Validação da ingestão	13
4.2.4 Persistência na camada Bronze	14
4.2.5 Ingestão das demais fontes	16
4.3 Camada Silver	19
4.3.1 Análise inicial e qualidade dos dados	19
4.3.2 Tratamento dos dados orçamentários da CAPES	22
4.3.3 Tratamento das demais fontes	28
4.3.4 Validação da camada Silver	29

4.4 Modelagem dos dados	31
4.5 Camada Gold	32
4.5.1 Criação das dimensões	33
4.5.2 Criação das tabelas fato	34
4.5.3 Validação da camada Gold	37
 5. CATÁLOGO DE DADOS	 39
5.1 Catálogo da dim_tempo	39
5.2 Catálogo da dim_orgao	40
5.3 Catálogo da dim_regiao	40
5.4 Catálogo da fato_orcamento	41
5.5 Catálogo da fato_bolsas	42
 6. ANÁLISE DE DADOS	 43
6.1 Evolução do orçamento da CAPES entre 2013 e 2020	43
6.2 Comparação entre os orçamentos da CAPES e do MEC	46
6.3 Participação da CAPES no orçamento do MEC	49
6.4 Evolução e distribuição das bolsas concedidas pela CAPES	51
 7. CONSIDERAÇÕES FINAIS	 55
 8. AUTOAVALIAÇÃO	 56

1. INTRODUÇÃO

A Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES) possui um papel importante no desenvolvimento da pós-graduação brasileira, atuando no financiamento de bolsas e no apoio aos programas de pós-graduação. Por ser uma instituição pública vinculada ao Ministério da Educação (MEC), suas atividades dependem dos recursos disponibilizados por meio do orçamento público federal.

Entre 2013 e 2020, o orçamento federal passou por diferentes mudanças. Nesse período, destaca-se a aprovação da Emenda Constitucional nº 95, em 2016, que estabeleceu um novo regime fiscal para os gastos públicos federais. A partir desse contexto, torna-se relevante observar como o orçamento da CAPES se comportou ao longo dos anos, assim como comparar sua trajetória com a do orçamento do MEC e com a evolução das bolsas concedidas pela instituição.

Para realizar essa análise, foram utilizadas diferentes bases de dados públicas, que apresentam estruturas e níveis de detalhamento distintos. Dessa forma, além da análise dos dados, o trabalho envolve a construção de um pipeline de Engenharia de Dados no Databricks para realizar a ingestão, o armazenamento, o tratamento e a integração dessas informações. Os dados foram organizados seguindo a arquitetura de medalhão, com as camadas Bronze, Silver e Gold, permitindo preservar os dados de origem, realizar os tratamentos necessários e disponibilizar informações consolidadas para análise.

A análise compreende o período entre 2013 e 2020, utilizando 2016 como marco para a comparação entre os períodos de 2013–2016 e 2017–2020. Essa divisão não pretende atribuir exclusivamente à Emenda Constitucional nº 95 as alterações encontradas, mas utilizá-la como uma referência temporal para observar o comportamento dos indicadores analisados.

2. OBJETIVO

Este trabalho tem como objetivo desenvolver um pipeline de Engenharia de Dados para integrar e analisar dados públicos relacionados ao orçamento da CAPES, ao orçamento do MEC e às bolsas concedidas pela instituição entre 2013 e 2020. A partir da construção das camadas Bronze, Silver e Gold, busca-se organizar e tratar os dados coletados, aplicar verificações de qualidade e disponibilizar informações que permitam analisar a evolução orçamentária da CAPES, sua relação com o orçamento do MEC e o comportamento das bolsas concedidas ao longo do período.

Para isso, busca-se responder:

- 1. Como a dotação e a execução orçamentária da CAPES evoluíram entre 2013 e 2020, especialmente na comparação entre os períodos anterior e posterior a 2016?**
- 2. As alterações observadas no orçamento da CAPES acompanharam o comportamento do orçamento do MEC ou a CAPES apresentou uma dinâmica distinta entre 2013 e 2020?**
- 3. Como evoluiu a participação do orçamento da CAPES em relação ao orçamento do MEC entre 2013 e 2020?**
- 4. As alterações observadas no orçamento da CAPES foram acompanhadas por mudanças na quantidade e na distribuição das bolsas concedidas pela instituição?**

3. CARGA DOS DADOS

3.1 FONTE DOS DADOS

Para a construção do pipeline, foram utilizadas bases de dados públicas relacionadas ao orçamento da CAPES, ao orçamento do Ministério da Educação (MEC) e às bolsas concedidas pela CAPES. A utilização dessas diferentes fontes permite analisar a evolução do orçamento da instituição, compará-la ao

orçamento do MEC e observar o comportamento das concessões de bolsas ao longo do período analisado.

Os dados orçamentários da CAPES compreendem os exercícios de 2013 a 2020 e foram disponibilizados em arquivos separados para cada ano. Para complementar essas informações, foram utilizados dados do orçamento do MEC, tanto em seu valor total quanto detalhados por Unidade Orçamentária. O detalhamento por unidade permite identificar especificamente a CAPES, correspondente à Unidade Orçamentária 26291. Por fim, foram incorporados os dados de concessão de bolsas da CAPES referentes ao mesmo período.

Em relação à estrutura dos dados brutos, a base orçamentária da CAPES apresenta atributos referentes ao exercício, unidade gestora, função, subfunção, programa, ação, natureza da despesa, fonte de recurso e valores de dotação e execução. As bases do MEC apresentam o ano e os valores de dotação inicial, dotação atual, empenhado, liquidado e pago, sendo que uma delas acrescenta o detalhamento por Unidade Orçamentária. Já a base de bolsas da CAPES contém informações referentes ao ano, instituição de ensino, município, unidade federativa, região, programa de fomento, área de conhecimento, nível e quantidade de bolsas concedidas.

3.1.1 Dados orçamentários da CAPES

Os arquivos utilizados foram baixados da URL:

<https://dadosabertos.capes.gov.br/dataset/2013-a-2020-dotacao-e-execucao-orcamentaria-da-capes>

- capes_2013.csv
- capes_2014.csv
- capes_2015.csv
- capes_2016.csv
- capes_2017.csv
- capes_2018.csv
- capes_2019.csv
- capes_2020.csv

3.1.2 Dados orçamentários do MEC

O arquivo utilizado foi retirado da URL:

https://www1.siof.planejamento.gov.br/QvAJAXZfc/opendoc.htm?document=IAS%2FExecucao_Orcamentaria.qvw&host=QVS%40pqlk04&anonymous=true&sheet=SH06.

Assim, foi selecionado o filtro “Órgão: MEC” e a opção “Detalhar por Órgão Orçamentário” para obter os dados do orçamento total. Para a segunda base, foi utilizada a opção “Detalhar por Unidade Orçamentária”, permitindo identificar os dados referentes à CAPES.

- MEC_Orcamento
- MEC_UnidadeOrcamentaria

A utilização de duas tabelas diferentes é dada pela granularidade e finalidades diferentes entre elas.

3.1.3 Dados das Bolsas CAPES

Os arquivos utilizados foram retirados das URLs:

<https://dadosabertos.capes.gov.br/dataset/2010-a-2016-concessao-de-bolsas-a-instituicoes-de-ensino-superior-apoiadas-pela-capes>

e

<https://dadosabertos.capes.gov.br/it/dataset/2017-a-2021-concessao-de-bolsas-a-instituicoes-de-ensino-superior-apoiadas-pela-capes>.

Assim, foram selecionados os CSVs dos anos de análise (2013 – 2020), e os arquivos foram baixados e renomeados respectivamente conforme abaixo.

- bolsas_2013
- bolsas_2014
- bolsas_2015
- bolsas_2016

- bolsas_2017
- bolsas_2018
- bolsas_2019
- bolsas_2020

3.1.4 Licença e utilização dos dados

As bases utilizadas neste trabalho são provenientes de fontes públicas governamentais. Os conjuntos disponibilizados pela CAPES fazem parte de sua política de Dados Abertos, que permite o livre acesso, utilização, modificação e compartilhamento das informações, preservando a indicação de sua origem. Os dados orçamentários obtidos por meio do SIOF também são disponibilizados como dados abertos do Orçamento Federal e integram a política de disponibilização de informações públicas do Governo Federal. Dessa forma, os dados utilizados neste projeto podem ser reutilizados para fins de análise, mantendo-se a identificação e os créditos das respectivas fontes.

3.2 AMBIENTE UTILIZADO

O pipeline foi desenvolvido no Databricks Free Edition, utilizado tanto para o armazenamento quanto para o processamento e análise dos dados. Os arquivos originais foram armazenados em Volumes e posteriormente carregados em tabelas Delta, permitindo organizar o pipeline em diferentes camadas. Para a estruturação dos dados, foi adotada a arquitetura de medalhão, dividindo o processo entre as camadas Bronze, Silver e Gold. A camada Bronze foi utilizada para preservar os dados próximos ao formato de origem, enquanto a Silver concentra os tratamentos e padronizações necessários. Por fim, a camada Gold disponibiliza os dados consolidados e as métricas utilizadas nas análises.

3.3 ARMAZENAMENTO DOS ARQUIVOS NO DATABRICKS

Inicialmente, os arquivos originais utilizados no projeto foram armazenados em Volumes no ambiente do Databricks, permitindo manter os

arquivos de origem separados das tabelas posteriormente criadas durante o desenvolvimento do pipeline. Os dados foram mantidos em seus formatos originais, sem a aplicação de tratamentos antes do carregamento. A partir desses arquivos, foi realizada a ingestão dos dados para a camada Bronze, dando início às etapas de processamento do pipeline. A Figura 1 apresenta um exemplo do armazenamento dos arquivos referentes ao orçamento da CAPES no Volume utilizado durante o projeto.




Figura 1 - Arquivos brutos da CAPES armazenados no Volume do Databricks

A utilização do Volume permite manter os arquivos de origem armazenados separadamente das tabelas produzidas pelo pipeline, preservando os dados utilizados na ingestão e permitindo sua rastreabilidade durante as etapas seguintes.

4. PIPELINE DE DADOS

Após o armazenamento dos arquivos de origem, iniciou-se a construção do pipeline, dividido entre as camadas Bronze, Silver e Gold. Cada camada corresponde a uma etapa específica do processamento: a Bronze concentra a ingestão e preservação dos dados próximos à origem; a Silver realiza verificações de qualidade, tratamentos e padronizações; e a Gold organiza os dados em estruturas voltadas às perguntas de negócio e às análises finais.

4.1 PREPARAÇÃO DO AMBIENTE

Antes de iniciar a ingestão dos dados, foi realizada a preparação da estrutura utilizada pelo pipeline no Databricks. Para organizar as tabelas produzidas durante o projeto, foi criado o catálogo mvp, dividido entre os schemas bronze, silver e gold. O desenvolvimento do pipeline foi dividido em notebooks distintos, de forma que cada etapa pudesse ser executada e validada separadamente. Essa organização foi feita para facilitar a manutenção e a reprodução do processo a partir dos arquivos disponibilizados no repositório GitHub.

O primeiro notebook é responsável pela **preparação** do ambiente, criando o catálogo e os schemas utilizados pelo projeto. Em seguida, o notebook da **camada Bronze** realiza a leitura dos arquivos armazenados nos Volumes, a consolidação dos arquivos anuais quando necessário e a persistência das quatro bases em tabelas Delta. O notebook da **camada Silver** concentra as verificações de qualidade, remoção das duplicidades identificadas, padronização dos tipos e tratamento dos campos utilizados nas análises. Por fim, o notebook da **camada Gold** cria as dimensões e tabelas fato do modelo dimensional e contém as consultas utilizadas para responder às perguntas de negócio.

```
%sql

USE CATALOG mvp;

CREATE SCHEMA IF NOT EXISTS bronze;
CREATE SCHEMA IF NOT EXISTS silver;
CREATE SCHEMA IF NOT EXISTS gold;
```

A estrutura criada pode ser observada por meio da consulta abaixo:

```
%sql
```

```
SHOW SCHEMAS IN mvp;
```

> [See performance \(1\)](#)

	databaseName
1	bronze
2	gold
3	information_schema
4	silver

4.2 CAMADA BRONZE

A camada Bronze corresponde à etapa de ingestão dos arquivos armazenados nos Volumes. Nessa etapa, buscou-se manter os dados próximos de sua estrutura original, sem a aplicação de tratamentos ou filtros. Os arquivos referentes ao orçamento da CAPES, ao orçamento do MEC e às bolsas concedidas pela CAPES foram carregados e armazenados em tabelas no formato Delta. Nos casos em que os dados estavam separados por ano, como nas bases de orçamento e de bolsas da CAPES, os arquivos foram reunidos durante a ingestão, permitindo concentrar os diferentes anos em uma mesma tabela.

Além das informações presentes nos arquivos originais, foram acrescentados os campos *ARQUIVO_ORIGEM* e *DT_INGESTAO*. Esses campos permitem identificar, respectivamente, o arquivo de origem de cada registro e o momento em que sua ingestão foi realizada, contribuindo para a rastreabilidade dos dados durante as etapas seguintes do pipeline.

4.2.1 Ingestão dos dados

A ingestão foi realizada por meio de notebooks desenvolvidos no Databricks. Para os dados orçamentários da CAPES, foi criado inicialmente o notebook *01_ingestao_bronze_capes*, responsável pela leitura dos oito arquivos

CSV correspondentes aos anos de 2013 a 2020 e por sua consolidação em uma única estrutura. Após a leitura, os registros foram armazenados na tabela *mvp.bronze.orcamento_capes* em formato Delta. As demais fontes também foram carregadas para a camada Bronze, respeitando a estrutura de seus arquivos de origem. Ao final do processo de ingestão, foram criadas as quatro tabelas apresentadas na Figura 2.




Figura 2 - Tabelas armazenadas na camada Bronze.

4.2.2 Leitura dos arquivos

Para realizar a leitura dos dados orçamentários da CAPES, foi definido inicialmente o caminho do Volume onde os arquivos de origem estavam armazenados.

```
# Verificando a existência do arquivo
caminho = "/Volumes/workspace/default/capes_dados/*.csv"
```

Após a identificação dos arquivos disponíveis no diretório, os dados foram carregados utilizando PySpark.

```
# Lendo os dados do arquivo
df_bronze = (
    spark.read
        .option("header", "true") # Lê a primeira linha como cabeçalho
        .option("sep", ";") # Separação por ;
        .option("inferSchema", "false") # Mantém os campos como string na camada bronze; as conversões serão realizadas na Silver
        .csv(caminho) # lê os arquivos csv
)
```

Na leitura, foi utilizada a opção *header = true*, indicando que a primeira linha dos arquivos corresponde ao nome dos atributos, e *sep = ";"*, uma vez que os arquivos disponibilizados pela CAPES utilizam o ponto e vírgula como delimitador. Também foi definido *inferSchema = false*, evitando a inferência automática dos tipos durante a ingestão. Dessa forma, as conversões

necessárias foram deixadas para a etapa de tratamento dos dados na camada Silver.

Durante esse processo, também foram acrescentados os dois atributos técnicos de rastreabilidade apresentados anteriormente.

```
12:52 PM (-1s) 6 Python
# Aciona metadados técnicos à camada bronze
from pyspark.sql.functions import current_timestamp, col

df_bronze = (
    df_bronze
    .withColumn("ARQUIVO_ORIGEM", col("_metadata.file_path")) # Verifica de qual CSV o registro veio
    .withColumn("DT_INGESTAO", current_timestamp()) # Registra a data de ingestão
)

> df_bronze: pyspark.sql.connect.dataframe.DataFrame = [AN_ORCAMENTO: string, CD_UNIDADE_GESTORA: string ... 37 more fields]
```

4.2.3 Validação da ingestão

Após a leitura dos arquivos e a inclusão dos metadados, foram realizadas verificações para confirmar se a ingestão havia ocorrido corretamente. Inicialmente, foram verificadas a quantidade total de registros e de atributos presentes no conjunto de dados.



```
%sql
SELECT
  COUNT(*) AS QTD_REGISTROS
FROM vw_bronze_capes;
```

> [See performance \(1\)](#)

Table		+	
	1 ² QTD_REGISTROS		
1	15739		

A consulta retornou **15.739 registros**, correspondentes à consolidação dos arquivos utilizados no período analisado. Em seguida, os registros foram agrupados por exercício orçamentário, permitindo verificar a presença dos dados referentes a cada um dos anos entre 2013 e 2020.

SELECT

```

AN_ORCAMENTO,
COUNT(*) AS QTD_REGISTROS
FROM vw_bronze_capes
GROUP BY AN_ORCAMENTO
ORDER BY AN_ORCAMENTO;

```

> [See performance \(1\)](#)

Table +

	A ^B _C AN_ORCAMENTO	1 ² ₃ QTD_REGISTROS
1	2013	2422
2	2014	2211
3	2015	1774
4	2016	1952
5	2017	1956
6	2018	2032
7	2019	1888
8	2020	1504

Essa verificação permitiu confirmar que os oito exercícios estavam presentes na estrutura consolidada e observar a quantidade de registros proveniente de cada ano antes da persistência dos dados na camada Bronze.

4.2.4 Persistência na camada Bronze

Após a validação da carga, os dados foram armazenados em formato Delta na camada Bronze. Para isso, foi criada a tabela *mvp.bronze.orcamento_capes* a partir da view temporária utilizada durante a ingestão.

```
%sql

CREATE OR REPLACE TABLE mvp.bronze.orcamento_capes
USING DELTA
AS

SELECT *
FROM vw_bronze_capes;

See performance (1)
```

Table	
1^2_3 num_affected_rows	1^2_3 num_inserted_rows

Com a criação da tabela, os dados passaram a ficar armazenados de forma persistente no catálogo *mvp*, podendo ser utilizados nas etapas seguintes do pipeline sem a necessidade de realizar novamente a leitura dos arquivos CSV de origem. Após a persistência, também foi verificada a presença dos campos técnicos de rastreabilidade na tabela criada. Para isso, foram consultados os atributos referentes ao exercício orçamentário, ao arquivo de origem e à data de ingestão.

```
%sql

-- Valida a presença dos campos técnicos de rastreabilidade.

SELECT
  AN_ORCAMENTO,
  ARQUIVO_ORIGEM,
  DT_INGESTAO
FROM mvp.bronze.orcamento_capes
LIMIT 10;
```

A consulta permitiu confirmar que os campos *ARQUIVO_ORIGEM* e *DT_INGESTAO* foram mantidos após a persistência, preservando as informações necessárias para identificar a origem dos registros durante as etapas seguintes do pipeline.

Por fim, foi realizada uma nova contagem dos registros por exercício orçamentário diretamente sobre a tabela Delta persistida. Os resultados permaneceram consistentes com a verificação realizada anteriormente,

confirmando a presença dos oito exercícios entre 2013 e 2020 e a manutenção dos 15.739 registros após a persistência.

```
Just now (1s) 11 Python
```

```
# Confirma a quantidade de registros por exercício na tabela Bronze persistida
```

```
spark.sql("""
SELECT
    AN_ORCAMENTO,
    COUNT(*) AS QTD_REGISTROS
FROM mvp_bronze.orcamento_capes
GROUP BY AN_ORCAMENTO
ORDER BY AN_ORCAMENTO
""").show()
```

See performance (1) ✓ Checked for improvements

AN_ORCAMENTO	QTD_REGISTROS
2013	2422
2014	2211
2015	1774
2016	1952
2017	1956
2018	2032
2019	1888
2020	1504

4.2.5 Ingestão das demais fontes

Após a ingestão dos dados orçamentários da CAPES, foram carregadas as demais bases utilizadas no projeto. Embora o processo de ingestão tenha seguido a mesma estrutura apresentada anteriormente, algumas diferenças foram consideradas de acordo com a organização de cada fonte. Para os dados do MEC, os dois arquivos foram carregados a partir do Volume onde os dados de origem estavam armazenados.

```
# Realiza a leitura do arquivo de orçamento do MEC
df_mec_bronze = (
    spark.read
        .option("header", "true")
        .option("sep", ";") # O arquivo utiliza ; como separador
        .option("inferSchema", "false") # Mantém os campos como string na Bronze
        .csv(caminho_mec)
)

display(df_mec_bronze)
```

```
# Realiza a leitura do arquivo de orçamento do MEC por Unidade Orçamentária
df_mec_unidades_bronze = (
    spark.read
        .option("header", "true")
        .option("sep", ";") # O arquivo utiliza ; como separador
        .option("inferSchema", "false") # Mantém os campos como string na Bronze
        .csv(caminho_mec_unidades)
)

display(df_mec_unidades_bronze)
```

Após a leitura, os dados foram mantidos próximos de sua estrutura original e receberam os mesmos campos técnicos de rastreabilidade utilizados anteriormente. Antes da persistência, foi necessário realizar uma padronização nos nomes dos atributos, substituindo os nomes originais por uma nomenclatura compatível com a criação das tabelas Delta. Essa alteração foi restrita aos nomes dos campos, sem modificar os valores presentes nos arquivos de origem.

```
%sql

-- Padroniza os nomes das colunas para permitir a persistência em Delta.

CREATE OR REPLACE TEMP VIEW vw_bronze_mec_padronizado AS

SELECT
    `Ano` AS ANO,
    `Órgão Orcamentário` AS ORGAO_ORCAMENTARIO,
    `Projeto de Lei` AS PROJETO_LEI,
    `Dotação Inicial` AS DOTACAO_INICIAL,
    `Dotação Atual` AS DOTACAO_ATUAL,
    `Empenhado` AS EMPENHADO,
    `Liquidado` AS LIQUIDADO,
    `Pago` AS PAGO,
    ARQUIVO_ORIGEM,
    DT_INGESTAO
FROM vw_bronze_mec;
```

Após a padronização, os dados foram armazenados em formato Delta na tabela *mvp.bronze.orcamento_mec*.

```
%sql

-- Persiste os dados padronizados do MEC como tabela Delta na camada Bronze.

CREATE OR REPLACE TABLE mvp.bronze.orcamento_mec
USING DELTA
AS

SELECT *
FROM vw_bronze_mec_padronizado;
```

O mesmo procedimento foi aplicado à base detalhada por Unidade Orçamentária, que foi armazenada separadamente na tabela *mvp.bronze.orcamento_mec_unidades*.

```
%sql

-- Persiste os dados do MEC por Unidade Orçamentária na camada Bronze.

CREATE OR REPLACE TABLE mvp.bronze.orcamento_mec_unidades
USING DELTA
AS

SELECT *
FROM vw_bronze_mec_unidades_padronizado;
```

A manutenção das duas bases em tabelas distintas permite preservar suas diferentes granularidades. Enquanto a primeira apresenta os valores do orçamento total do MEC, a segunda possibilita consultar os dados por Unidade Orçamentária, incluindo aqueles referentes à CAPES.

Para os dados de bolsas da CAPES, foram utilizados oito arquivos CSV correspondentes aos anos de 2013 a 2020, e como os dados estavam separados por ano, os arquivos foram reunidos durante a ingestão, para concentrar todo o período analisado em uma única estrutura.

```
# Realiza a leitura dos arquivos de concessão de bolsas da CAPES
df_bolsas_bronze = (
    spark.read
    .option("header", "true")
    .option("sep", ",")
    .option("inferSchema", "false") # Mantém os campos como string na Bronze
    .csv(caminho_bolsas)
)

display(df_bolsas_bronze)
```

Assim como nas demais bases, foram acrescentados os campos técnicos de rastreabilidade e, após a ingestão, os dados foram armazenados em formato Delta na tabela *mvp.bronze.bolsas_capes*.

```
%sql

-- Persiste os dados de bolsas da CAPES como uma tabela Delta na camada Bronze.

CREATE OR REPLACE TABLE mvp.bronze.bolsas_capes
USING DELTA
AS
SELECT *
FROM vw_bronze_bolsas;
```

Ao final desse processo, a camada Bronze passou a reunir as quatro tabelas utilizadas no projeto: os dados orçamentários detalhados da CAPES, o orçamento total do MEC, o orçamento do MEC por Unidade Orçamentária e os dados de bolsas concedidas pela CAPES. Com isso, as diferentes fontes ficaram disponíveis de forma persistente para os tratamentos realizados posteriormente na camada Silver.

4.3 CAMADA SILVER

Após a ingestão dos dados na camada Bronze, iniciou-se a etapa de tratamento e padronização das bases. A camada Silver foi utilizada para preparar os dados para as análises posteriores, realizando os ajustes necessários nos tipos dos atributos e tratando inconsistências identificadas durante a análise inicial dos dados. Como as fontes utilizadas apresentam estruturas distintas, os tratamentos foram realizados de acordo com as características de cada base. Ao final dessa etapa, os dados tratados foram armazenados no schema `mvp.silver`, mantendo a separação entre as quatro fontes utilizadas no projeto.

4.3.1 Análise inicial e qualidade dos dados

Antes da realização dos tratamentos, foram feitas verificações sobre as tabelas armazenadas na camada Bronze, buscando identificar possíveis inconsistências que pudessem afetar as etapas seguintes do pipeline. Inicialmente, foi analisada a presença de valores ausentes e de registros duplicados nas quatro bases utilizadas no projeto. Para a análise dos valores ausentes, foi criada uma função responsável por verificar cada atributo das tabelas. Nos campos de texto, foram considerados tanto os valores nulos quanto os campos vazios, enquanto nos demais tipos foi verificada a presença de valores nulos. Além da quantidade de ocorrências, também foi calculado o percentual de valores ausentes em relação ao total de registros de cada base.

```

# Calcula a quantidade e o percentual de valores ausentes por coluna

from pyspark.sql.functions import col, sum, when
from pyspark.sql.types import StringType

# Cria uma função para analisar os valores ausentes de cada DataFrame.
def resumo_nulos(df, nome):

    # Conta a quantidade total de registros da tabela.
    total = df.count()

    # Cria uma lista para armazenar os resultados.
    resultados = []

    # Percorre todos os atributos da tabela.
    for campo in df.schema.fields:

        # Para atributos do tipo string, verifica valores nulos ou vazios.
        if isinstance(campo.dataType, StringType):
            condicao = col(campo.name).isNull() | (col(campo.name) == "")

        # Para os demais tipos, verifica apenas valores nulos.
        else:
            condicao = col(campo.name).isNull()

        # Conta a quantidade de valores ausentes no atributo.
        qtd = (
            df.select(
                sum(when(condicao, 1).otherwise(0)).alias("qtd")
            )
            .collect()[0]["qtd"]
        )

        # Armazena o nome da coluna, a quantidade e o percentual de valores ausentes.
        resultados.append(
            (
                campo.name,
                qtd,
                round((qtd / total) * 100, 2)
            )
        )

    # Exibe o nome da tabela analisada.
    print(f"\n--- {nome} ---")

```

```

# Exibe os resultados ordenados pelo maior percentual de valores ausentes.
spark.createDataFrame(
    resultados,
    ["COLUNA", "QTD_AUSENTES", "PERCENTUAL_AUSENTES"]
).orderBy(
    col("PERCENTUAL_AUSENTES").desc()
).show(truncate=False)

# Executa a análise para cada tabela da camada Bronze.
resumo_nulos(df_capes, "ORÇAMENTO CAPES")
resumo_nulos(df_mec, "ORÇAMENTO MEC")
resumo_nulos(df_mec_unidades, "UNIDADES MEC")
resumo_nulos(df_bolsas, "BOLSAS CAPES")

```

Os resultados mostraram que a maior ocorrência de valores ausentes estava concentrada em alguns atributos da base orçamentária da CAPES. Entre os campos com maior percentual de ausência estão aqueles relacionados à dotação suplementar, ao crédito bloqueado e a determinados valores de dotação e execução. Apesar da quantidade de valores ausentes em alguns atributos, optou-se por não realizar sua substituição automática por zero, já que a ausência de determinado valor pode estar relacionada à própria estrutura do registro orçamentário, e sua substituição poderia alterar a interpretação dos dados.

Em seguida, foi verificada a existência de possíveis registros duplicados. Para essa análise, os campos *ARQUIVO_ORIGEM* e *DT_INGESTAO* foram desconsiderados, uma vez que correspondem aos metadados técnicos acrescentados durante a ingestão e poderiam diferenciar registros que apresentassem os mesmos dados de origem.

```

# Verifica a existência de possíveis registros duplicados nas tabelas da camada Bronze
# Cria um dicionário contendo o nome de cada base e seu respectivo DataFrame.
tabelas = {
    "ORÇAMENTO CAPES": df_capes,
    "ORÇAMENTO MEC": df_mec,
    "UNIDADES MEC": df_mec_unidades,
    "BOLSAS CAPES": df_bolsas
}

# Percorre individualmente cada uma das tabelas definidas anteriormente.
for nome, df in tabelas.items():
    # Conta a quantidade total de registros existentes na tabela.
    total = df.count()
    # Seleciona apenas as colunas provenientes dos dados originais.
    colunas_dados = [
        c for c in df.columns
        if c not in ["ARQUIVO_ORIGEM", "DT_INGESTAO"]
    ]
    # Seleciona somente as colunas originais e utiliza distinct() para identificar quantas combinações de registros são únicas.
    distintos = (
        df
        .select(colunas_dados)
        .distinct()
        .count()
    )
    # Calcula a quantidade de possíveis registros duplicados.
    duplicados = total - distintos
    # Exibe os resultados da análise para cada tabela.
    print(f"--- {nome} ---")
    print(f"Registros totais: {total}")
    print(f"Registros distintos: {distintos}")
    print(f"Possíveis duplicados: {duplicados}")
    print()

```

A análise identificou oito registros duplicados na base orçamentária da CAPES, enquanto as demais bases não apresentaram duplicidades. Dessa forma, a remoção desses registros foi considerada durante o tratamento dos dados da CAPES na camada Silver.

4.3.2 Tratamento dos dados orçamentários da CAPES

A partir das verificações realizadas, iniciou-se o tratamento dos dados orçamentários da CAPES. O primeiro ajuste realizado foi a remoção dos oito registros duplicados identificados na etapa anterior. Para isso, foram considerados os atributos originais da base, desconsiderando os campos técnicos de rastreabilidade, e mantida apenas uma ocorrência para cada conjunto de registros repetidos.

A remoção das duplicidades foi incorporada diretamente à construção da tabela Silver. Para identificar os registros repetidos, foi utilizada a função ROW_NUMBER(), agrupando os registros pelos atributos originais da base e ordenando-os pela data de ingestão. Dessa forma, apenas a primeira ocorrência de cada conjunto de registros iguais foi mantida.

```
%sql

CREATE OR REPLACE TABLE.mvp.silver.orcamento_capes
USING DELTA
AS

WITH capes_sem_duplicados AS (
```

```
SELECT *
FROM (
  SELECT
    *,
    ROW_NUMBER() OVER (
      PARTITION BY
        AN_ORCAMENTO,
        CD_UNIDADE_GESTORA,
        DS_UNIDADE_GESTORA,
        CD_FUNCAO_ORCAMENTARIA,
        DS_FUNCAO_ORCAMENTARIA,
        CD_SUBFUNCAO_ORCAMENTARIA,
        DS_SUBFUNCAO_ORCAMENTARIA,
        CD_PROGRAMA_GOVERNO,
        DS_PROGRAMA_GOVERNO,
        CD_ACAO,
        DS_ACAO,
        CD_PLANO_ORCAMENTARIO,
        DS_PLANO_ORCAMENTARIO,
        DS_PROGRAMA_TRABALHO,
        CD_PTRES,
        CD_PLANO_INTERNO,
        DS_PLANO_INTERNO,
        CD_MODALIDADE_APLICACAO,
        DS_MODALIDADE_APLICACAO,
        CD_CATEGORIA_ECONOMICA,
        DS_CATEGORIA_ECONOMICA,
        CD_GRUPO_DESPESA,
        DS_GRUPO_DESPESA,
        CD_ELEMENTO_DESPESA,
        DS_ELEMENTO_DESPESA,
        CD_NATUREZA_DESPESA,
        DS_NATUREZA_DESPESA,
        CD_FONTE_RECURSO,
        DS_FONTE_RECURSO,
        VL_DOTACAO_INICIAL,
        VL_DOTACAO_SUPLEMENTAR,
        VL_DOTACAO_DISPONIVEL,
        VL_CREDITO_BLOQUEADO,
        VL_DESPESAS_EMPENHADAS,
        VL_EM_A_LIQUIDAR,
        VL_EM_LIQUIDADO,
        VL_DESPESAS_PAGAS
      ORDER BY DT_INGESTAO
    ) AS rn
  FROM.mvp.bronze.orcamento_capes
)
WHERE rn = 1
```

Após a remoção das duplicidades, foram realizados os ajustes nos tipos dos atributos utilizados nas análises. Como os dados haviam sido preservados

inicialmente como texto na camada Bronze, foi necessário converter o exercício orçamentário para o tipo inteiro e os campos relacionados aos valores orçamentários para DECIMAL(18,2). Como a mesma lógica de conversão era necessária em diferentes atributos monetários, foi criada uma função temporária chamada tratar_valor. Essa função centraliza o tratamento dos valores, considerando os casos em que números negativos estavam representados entre parênteses, removendo os separadores presentes nos arquivos de origem e realizando a conversão para o tipo decimal.

```
CREATE OR REPLACE TEMPORARY FUNCTION tratar_valor(valor STRING)
RETURNS DECIMAL(18,2)
RETURN
  TRY_CAST(
    CASE
      WHEN TRIM(valor) LIKE '(%)' THEN
        CONCAT(
          '-',
          REPLACE(
            REPLACE(
              REPLACE(TRIM(valor), '(', ''),
              ')',
              ''
            ),
            ',',
            ''
          )
        )
      ELSE REPLACE(TRIM(valor), ',', '')
    END
    AS DECIMAL(18,2)
  );
```

A função foi então aplicada aos oito atributos monetários da base durante a criação da tabela `mvp.silver.orcamento_capes`. O exercício orçamentário também foi convertido para o tipo inteiro, enquanto os demais atributos descritivos foram preservados.

```

CREATE OR REPLACE TABLE mvp.silver.orcamento_capes
USING DELTA
AS

WITH capes_sem_duplicados AS (

    SELECT *
    FROM (
        SELECT
            *,
            ROW_NUMBER() OVER (
                PARTITION BY
                    AN_ORCAMENTO,
                    CD_UNIDADE_GESTORA,
                    DS_UNIDADE_GESTORA,
                    CD_FUNCAO_ORCAMENTARIA,
                    DS_FUNCAO_ORCAMENTARIA,
                    CD_SUBFUNCAO_ORCAMENTARIA,
                    DS_SUBFUNCAO_ORCAMENTARIA,
                    CD_PROGRAMA_GOVERNO,
                    DS_PROGRAMA_GOVERNO,
                    CD_ACAO,
                    DS_ACAO,
                    CD_PLANO_ORCAMENTARIO,
                    DS_PLANO_ORCAMENTARIO,
                    DS_PROGRAMA_TRABALHO,
                    CD_PTRES,
                    CD_PLANO_INTERNO,
                    DS_PLANO_INTERNO,
                    CD_MODALIDADE_APLICACAO,
                    DS_MODALIDADE_APLICACAO,
                    CD_CATEGORIA_ECONOMICA,
                    DS_CATEGORIA_ECONOMICA,
                    CD_GRUPO_DESPESA,
                    DS_GRUPO_DESPESA,
                    CD_ELEMENTO_DESPESA,
                    DS_ELEMENTO_DESPESA,
                    CD_NATUREZA_DESPESA,
                    DS_NATUREZA_DESPESA,
                    CD_FONTE_RECURSO,
                    DS_FONTE_RECURSO,
                    VL_DOTACAO_INICIAL,
                    VL_DOTACAO_SUPLEMENTAR,
                    VL_DOTACAO_DISPONIVEL,
                    VL_CREDITO_BLOQUEADO,
                    VL_DESPESAS_EMPENHADAS,
                    VL_EM_A_LIQUIDAR,
                    VL_EM_LIQUIDADO,
                    VL_DESPESAS_PAGAS
                ORDER BY DT_INGESTAO
            ) AS rn
        FROM mvp.bronze.orcamento_capes
    )
    WHERE rn = 1

```

```

SELECT
    CAST(AN_ORCAMENTO AS INT) AS AN_ORCAMENTO,

    CD_UNIDADE_GESTORA,
    DS_UNIDADE_GESTORA,

    CD_FUNCAO_ORCAMENTARIA,
    DS_FUNCAO_ORCAMENTARIA,

    CD_SUBFUNCAO_ORCAMENTARIA,
    DS_SUBFUNCAO_ORCAMENTARIA,

    CD_PROGRAMA_GOVERNO,
    DS_PROGRAMA_GOVERNO,

    CD_ACAO,
    DS_ACAO,

    CD_PLANO_ORCAMENTARIO,
    DS_PLANO_ORCAMENTARIO,

    DS_PROGRAMA_TRABALHO,

    CD_PTRES,

    CD_PLANO_INTERNO,
    DS_PLANO_INTERNO,

    CD_MODALIDADE_APLICACAO,
    DS_MODALIDADE_APLICACAO,

    CD_CATEGORIA_ECONOMICA,
    DS_CATEGORIA_ECONOMICA,

    CD_GRUPO_DESPESA,
    DS_GRUPO_DESPESA,

    CD_ELEMENTO_DESPESA,
    DS_ELEMENTO_DESPESA,

    CD_NATUREZA_DESPESA,
    DS_NATUREZA_DESPESA,

    CD_FONTE_RECURSO,
    DS_FONTE_RECURSO,

```

```

    tratar_valor(VL_DOTACAO_INICIAL)
    AS VL_DOTACAO_INICIAL,

    tratar_valor(VL_DOTACAO_SUPLEMENTAR)
    AS VL_DOTACAO_SUPLEMENTAR,

    tratar_valor(VL_DOTACAO_DISPONIVEL)
    AS VL_DOTACAO_DISPONIVEL,

    tratar_valor(VL_CREDITO_BLOQUEADO)
    AS VL_CREDITO_BLOQUEADO,

    tratar_valor(VL_DESPESAS_EMPENHADAS)
    AS VL_DESPESAS_EMPENHADAS,

    tratar_valor(VL_EM_A_LIQUIDAR)
    AS VL_EM_A_LIQUIDAR,

    tratar_valor(VL_EM_LIQUIDADO)
    AS VL_EM_LIQUIDADO,

    tratar_valor(VL_DESPESAS_PAGAS)
    AS VL_DESPESAS_PAGAS,

    ARQUIVO_ORIGEM,
    DT_INGESTAO

FROM capes_sem_duplicados;

```

Com a aplicação desses tratamentos, os dados foram armazenados na tabela `mvp.silver.orcamento_capes`, já com a remoção dos registros duplicados e com os principais atributos convertidos para tipos adequados às operações realizadas nas etapas seguintes. Após a persistência, foi realizada uma nova contagem dos registros para confirmar o resultado do tratamento. A tabela apresentou **15.731 registros**, correspondentes aos 15.739 registros originalmente presentes na camada Bronze menos as oito duplicidades identificadas.

```
%sql
```

```
SELECT
    COUNT(*) AS QTD_REGISTROS
FROM mvp.silver.orcamento_capes;
```

> [See performance \(1\)](#)

Table	
	QTD_REGISTROS
1	15731

4.3.3 Tratamento das demais fontes

Após o tratamento dos dados orçamentários da CAPES, o processo de padronização foi aplicado às demais bases utilizadas no projeto. Para os dados do MEC, foram realizados principalmente ajustes nos tipos dos atributos, permitindo que os campos utilizados nas análises fossem armazenados em formatos adequados. Nas duas bases do MEC, o atributo referente ao ano foi convertido para um tipo inteiro, enquanto os campos relacionados aos valores orçamentários foram convertidos para o tipo decimal. Também foram retirados os registros de totalização presentes nas bases de origem, uma vez que esses registros não correspondem a exercícios orçamentários específicos.

```
%sql

CREATE OR REPLACE TABLE mvp.silver.orcamento_mec
USING DELTA
AS

SELECT
  CAST(ANO AS INT) AS ANO,
  ORGAO_ORCAMENTARIO,
  CAST(REPLACE(PROJETO_LEI, '.', '' ) AS DECIMAL(18,2)) AS PROJETO_LEI,
  CAST(REPLACE(DOTACAO_INICIAL, '.', '' ) AS DECIMAL(18,2)) AS DOTACAO_INICIAL,
  CAST(REPLACE(DOTACAO_ATUAL, '.', '' ) AS DECIMAL(18,2)) AS DOTACAO_ATUAL,
  CAST(REPLACE(EMPENHADO, '.', '' ) AS DECIMAL(18,2)) AS EMPENHADO,
  CAST(REPLACE(LIQUIDADO, '.', '' ) AS DECIMAL(18,2)) AS LIQUIDADO,
  CAST(REPLACE(PAGO, '.', '' ) AS DECIMAL(18,2)) AS PAGO,
  ARQUIVO_ORIGEM,
  DT_INGESTAO
FROM mvp.bronze.orcamento_mec
WHERE ANO <> 'Total';
```

O mesmo procedimento foi aplicado à base detalhada por Unidade Orçamentária, mantendo sua estrutura separada na camada Silver e preservando o nível de detalhamento necessário para identificar os registros referentes à CAPES.

Para os dados de bolsas da CAPES, os principais ajustes também estiveram relacionados aos tipos dos atributos. O ano de referência e a quantidade de bolsas concedidas foram convertidos para tipos inteiros, enquanto os demais campos foram preservados para utilização nas análises posteriores.

```
%sql

CREATE OR REPLACE TABLE mvp.silver.bolsas_capes
USING DELTA
AS

SELECT
    CAST(AN_REFERENCIA AS INT) AS AN_REFERENCIA,
    NM_MUNICIPIO_IES_CAPES,
    SG_UF_IES_CAPES,
    NM_REGIAO_IES_CAPES,
    CD_IES_CAPES,
    NM_IES_CAPES,
    SG_IES_CAPES,
    NM_NATUREZA_JURIDICA,
    SG_PROGRAMA_FOMENTO,
    CD_PROGRAMA,
    NM_PROGRAMA,
    NM_GRANDE_AREA,
    NM_AREA_AVALIACAO,
    NM_AREA_CONHECIMENTO,
    NM_NIVEL_PADRAO,
    CAST(QT_BOLSAS_CONCEDIDAS AS INT) AS QT_BOLSAS_CONCEDIDAS,
    ARQUIVO_ORIGEM,
    DT_INGESTAO
FROM mvp.bronze.bolsas_capes;
```

Com esses tratamentos, as demais bases foram armazenadas na camada Silver, mantendo a separação entre as diferentes fontes e com os principais atributos adequados às operações realizadas nas etapas seguintes.

4.3.4 Validação da camada Silver

Após a realização dos tratamentos, foi feita uma nova verificação das tabelas armazenadas na camada Silver, buscando confirmar a quantidade de registros disponíveis após as transformações realizadas.

```
%sql

SELECT 'ORCAMENTO_CAPES' AS TABELA, COUNT(*) AS QTD_REGISTROS
FROM mvp.silver.orcamento_capes

UNION ALL

SELECT 'ORCAMENTO_MEC', COUNT(*)
FROM mvp.silver.orcamento_mec

UNION ALL

SELECT 'MEC_UNIDADES', COUNT(*)
FROM mvp.silver.orcamento_mec_unidades

UNION ALL

SELECT 'BOLSAS_CAPES', COUNT(*)
FROM mvp.silver.bolsas_capes;

> See performance \(1\)
```

	TABELA	QTD_REGISTROS
1	ORCAMENTO_CAP...	15731
2	ORCAMENTO_MEC	28
3	MEC_UNIDADES	4059
4	BOLSAS_CAPES	103360

A contagem permitiu verificar a quantidade de registros mantidos em cada uma das quatro tabelas após os tratamentos realizados. No caso dos dados orçamentários da CAPES, a redução de 15.739 para 15.731 registros corresponde à remoção das oito duplicidades identificadas anteriormente. As demais bases mantiveram seus registros após as padronizações realizadas.

Por fim, foi verificada a disponibilidade das tabelas no schema *mvp.silver*, confirmando a persistência das quatro bases tratadas utilizadas nas etapas seguintes do pipeline.

```
%sql
SHOW TABLES IN mvp.silver;
```

> [See performance \(1\)](#)

	database	tableName	isTemporary
1	silver	bolsas_capes	false
2	silver	orcamento_capes	false
3	silver	orcamento_mec	false
4	silver	orcamento_mec_unidades	false
5		vw_capes_sem_duplicad...	true

Com a conclusão dessa etapa, as bases passaram a apresentar uma estrutura mais adequada para integração e análise, servindo como ponto de partida para a modelagem dos dados e para a construção da camada Gold.


4.4 MODELAGEM DOS DADOS

Após o tratamento e a padronização dos dados na camada Silver, foi realizada a modelagem das informações utilizadas nas análises do projeto. Para isso, os dados foram organizados em tabelas fato e dimensão, buscando separar as medidas analisadas dos atributos utilizados para sua identificação e classificação. Foram definidas duas tabelas fato. A *fato_orcamento* concentra os valores orçamentários da CAPES e do MEC, incluindo dotação inicial, dotação atual, valores empenhados, liquidados e pagos. Já a *fato_bolsas* reúne a quantidade de bolsas concedidas pela CAPES. As duas tabelas compartilham a dimensão *dim_tempo*, que contém os anos analisados e sua classificação entre os períodos de 2013 a 2016 e de 2017 a 2020. Essa organização permite realizar as comparações temporais definidas nas perguntas do projeto. Para os dados orçamentários, foi criada a dimensão *dim_orgao*, utilizada para identificar a CAPES e o MEC. Para os dados de bolsas, foi criada a dimensão *dim_regiao*, permitindo analisar a distribuição das bolsas entre as regiões brasileiras.

Embora a camada Silver mantenha informações mais detalhadas sobre as bolsas, como instituição de ensino, programa, área de conhecimento, nível, município e unidade federativa, esses atributos não foram incorporados ao modelo dimensional da camada Gold, pois não são necessários para responder

às perguntas definidas neste trabalho. Dessa forma, buscou-se manter um modelo mais simples e direcionado aos objetivos da análise.

A imagem abaixo, feita no aplicativo <https://drawsql.app>, apresenta o modelo desenvolvido e os relacionamentos entre as tabelas.



As tabelas fato possuem granularidades distintas. Na *fato_orcamento*, cada registro representa os valores orçamentários de um órgão em determinado ano. Na *fato_bolsas*, cada registro representa a quantidade de bolsas concedidas em determinado ano e região. A partir dessa estrutura, os dados podem ser agregados e comparados de acordo com as necessidades das quatro perguntas propostas no projeto.

4.5 CAMADA GOLD

Após o tratamento e a padronização realizados na camada Silver, os dados foram organizados de acordo com o modelo apresentado anteriormente, com a criação das dimensões e tabelas fato utilizadas para integração e análise das informações. A camada Gold foi construída com o objetivo de disponibilizar

os dados de forma adequada às perguntas definidas no projeto. Dessa forma, foram mantidos apenas os atributos necessários para as análises, permitindo relacionar as informações orçamentárias da CAPES e do MEC com o período analisado e, separadamente, observar a quantidade e a distribuição regional das bolsas concedidas pela CAPES.

4.5.1 Criação das dimensões

Inicialmente, foram construídas as dimensões *dim_tempo*, *dim_orgao* e *dim_regiao* utilizadas na organização dos dados da camada Gold. As dimensões *dim_tempo* e *dim_regiao* foram construídas a partir dos dados disponíveis na camada Silver, enquanto a *dim_orgao* foi definida com os dois órgãos considerados na análise, CAPES e MEC. Para cada dimensão, foram definidas chaves numéricas utilizadas posteriormente no relacionamento com as tabelas fato. A dimensão *dim_tempo* reúne os anos compreendidos entre 2013 e 2020.

Além do ano de referência, foi criado o atributo *periodo*, utilizado para classificar os registros entre os períodos de 2013–2016 e 2017–2020. Essa divisão permite realizar as comparações temporais propostas no trabalho. A dimensão *dim_orgao* foi criada para identificar os dois órgãos considerados na análise orçamentária, CAPES e MEC. Já a dimensão *dim_regiao* reúne as cinco regiões brasileiras presentes nos dados de concessão de bolsas. Dessa forma, as informações utilizadas para identificação e classificação dos registros permanecem separadas das medidas analisadas nas tabelas fato. **Os códigos utilizados para a construção das três dimensões são apresentados nas figuras a seguir.**

```
%sql

-- Dimensão temporal utilizada pelas duas tabelas fato.
CREATE OR REPLACE TABLE mvp.gold.dim_tempo
USING DELTA
AS
SELECT
    CAST(ROW_NUMBER() OVER (ORDER BY ano) AS INT) AS id_tempo,
    ano,
    CASE
        WHEN ano BETWEEN 2013 AND 2016 THEN '2013-2016'
        WHEN ano BETWEEN 2017 AND 2020 THEN '2017-2020'
    END AS periodo
FROM (
    SELECT DISTINCT AN_REFERENCIA AS ano
    FROM mvp.silver.bolsas_capes
    WHERE AN_REFERENCIA BETWEEN 2013 AND 2020
);
```

```
-- Identifica os dois órgãos utilizados na análise orçamentária.
CREATE OR REPLACE TABLE mvp.gold.dim_orgao
USING DELTA
AS
SELECT * FROM VALUES
    (1, '26291', 'CAPES', 'Fundação'),
    (2, '26000', 'MEC', 'Ministério')
AS dim_orgao (
    id_orgao,
    codigo_orgao,
    nome_orgao,
    tipo_orgao
);

-- Regiões utilizadas na análise da distribuição das bolsas.
CREATE OR REPLACE TABLE mvp.gold.dim_regiao
USING DELTA
AS
SELECT
    CAST(ROW_NUMBER() OVER (ORDER BY nome_regiao) AS INT) AS id_regiao,
    nome_regiao
FROM (
    SELECT DISTINCT
        NM_REGIAO_IES_CAPES AS nome_regiao
    FROM mvp.silver.bolsas_capes
    WHERE NM_REGIAO_IES_CAPES IS NOT NULL
);
```

4.5.2 Criação das tabelas fato

Após a criação das dimensões, foram construídas as tabelas fato_orcamento e fato_bolsas, responsáveis por concentrar as medidas utilizadas nas análises. A tabela fato_orcamento foi construída a partir dos dados

orçamentários tratados na camada Silver. Para o MEC, foram utilizados os valores totais anuais disponíveis na base de orçamento do órgão. Para a CAPES, foram utilizados os registros correspondentes à Unidade Orçamentária 26291 presentes na base detalhada do MEC por Unidade Orçamentária.

Essa escolha permitiu utilizar valores consolidados e comparáveis para as duas instituições. Cada registro da tabela representa um órgão em determinado ano e contém os valores de dotação inicial, dotação atual, empenhado, liquidado e pago.

```
%sql

-- Cria a fato de orçamento por ano e órgão.
CREATE OR REPLACE TABLE mvp.gold.fato_orcamento
USING DELTA
AS

-- Orçamento do MEC
SELECT
    t.id_tempo,
    o.id_orgao,
    m.DOTACAO_INICIAL AS dotacao_inicial,
    m.DOTACAO_ATUAL AS dotacao_atual,
    m.EMPENHADO AS empenhado,
    m.LIQUIDADO AS liquidado,
    m.PAGO AS pago
FROM mvp.silver.orcamento_mec m
INNER JOIN mvp.gold.dim_tempo t
    ON m.ANO = t.ano
INNER JOIN mvp.gold.dim_orgao o
    ON o.nome_orgao = 'MEC'
WHERE m.ANO BETWEEN 2013 AND 2020

UNION ALL
```

```

-- Orçamento da CAPES
SELECT
    t.id_tempo,
    o.id_orgao,
    c.DOTACAO_INICIAL,
    c.DOTACAO_ATUAL,
    c.EMPENHADO,
    c.LIQUIDADO,
    c.PAGO
FROM mvp.silver.orcamento_mec_unidades c

INNER JOIN mvp.gold.dim_tempo t
    ON c.ANO = t.ano

INNER JOIN mvp.gold.dim_orgao o
    ON o.nome_orgao = 'CAPES'

WHERE c.ANO BETWEEN 2013 AND 2020
    AND c.UNIDADE_ORCAMENTARIA LIKE '26291%';

```

A tabela fato_bolsas, por sua vez, foi construída a partir dos dados de concessão de bolsas da CAPES. Os registros foram agrupados por ano e região, sendo calculada a quantidade total de bolsas concedidas para cada combinação. Cada registro da tabela representa, portanto, a quantidade de bolsas concedidas em determinada região e ano. A tabela foi relacionada às dimensões dim_tempo e dim_regiao, permitindo posteriormente analisar tanto a evolução anual das concessões quanto sua distribuição entre as regiões brasileiras.

```

-- Cria a fato de bolsas agregada por ano e região.
CREATE OR REPLACE TABLE mvp.gold.fato_bolsas
USING DELTA
AS

SELECT
    t.id_tempo,
    r.id_regiao,
    SUM(b.QT_BOLSAS_CONCEDIDAS) AS quantidade_bolsas
FROM mvp.silver.bolsas_capes b

INNER JOIN mvp.gold.dim_tempo t
    ON b.AN_REFERENCIA = t.ano

INNER JOIN mvp.gold.dim_regiao r
    ON b.NM_REGIAO_IES_CAPES = r.nome_regiao

WHERE b.AN_REFERENCIA BETWEEN 2013 AND 2020

GROUP BY
    t.id_tempo,
    r.id_regiao;

```

4.5.3 Validação da camada Gold

Após a construção das dimensões e das tabelas fato, foram realizadas verificações para confirmar a preservação dos dados utilizados nas análises. Inicialmente, foi verificada a quantidade de registros presentes nas duas tabelas fato. A fato_orcamento apresentou 16 registros, correspondentes aos oito anos analisados para os dois órgãos considerados, CAPES e MEC. Para a fato_bolsas, foram mantidos 40 registros, correspondentes às cinco regiões brasileiras ao longo dos oito anos analisados. Além da quantidade de registros, foi comparado o total de bolsas registrado na camada Silver com o total obtido após a agregação na camada Gold. Essa verificação permite identificar possíveis perdas ou duplicações durante os relacionamentos e agregações realizados na construção da tabela fato.

```

-- Valida a quantidade de registros e o total de bolsas na Gold.
SELECT
    'Registros fato_orcamento' AS validacao,
    COUNT(*) AS valor
FROM.mvp.gold.fato_orcamento

UNION ALL

SELECT
    'Registros fato_bolsas',
    COUNT(*)
FROM.mvp.gold.fato_bolsas

UNION ALL

SELECT
    'Total bolsas Silver',
    SUM(QT_BOLSAS_CONCEDIDAS)
FROM.mvp.silver.bolsas_capes

UNION ALL

SELECT
    'Total bolsas Gold',
    SUM(quantidade_bolsas)
FROM.mvp.gold.fato_bolsas;

```

> [See performance \(1\)](#)

	validacao	valor
1	Total bolsas Silver	789773
2	Total bolsas Gold	789773
3	Registros fato_orcamen...	16
4	Registros fato_bolsas	40

A validação confirmou a presença dos 16 registros esperados na *fato_orcamento*, correspondentes aos oito anos analisados para os dois órgãos considerados, e dos 40 registros da *fato_bolsas*, resultantes da combinação entre os oito anos e as cinco regiões. Além disso, o total de 789.773 bolsas registrado na camada Silver foi preservado após a agregação na camada Gold. Dessa forma, não foram identificadas perdas ou duplicações na quantidade total de bolsas durante a construção da tabela fato.

5. CATÁLOGO DE DADOS

Após a construção das tabelas da camada Gold, foi elaborado o catálogo de dados correspondente ao modelo utilizado nas análises. O catálogo tem como objetivo documentar a estrutura das tabelas, apresentando seus campos, tipos de dados, descrições e origem das informações. O modelo final da camada Gold é composto por cinco tabelas: três dimensões (dim_tempo, dim_orgao e dim_regiao) e duas tabelas fato (fato_orcamento e fato_bolsas). As tabelas foram persistidas no Databricks no schema mvp.gold e constituem a estrutura utilizada posteriormente para responder às perguntas definidas no projeto.

5.1 CATÁLOGO DA DIM_TEMPO

Campo	Tipo	Descrição	Origem/Domínio
id_tempo	INT	Identificador da dimensão temporal.	Gerado na camada Gold.
ano	INT	Ano de referência dos dados.	2013 a 2020.
periodo	STRING	Período utilizado nas comparações temporais.	2013-2016 ou 2017-2020.

Q Filter columns...			
Column	Type	Popularity	Comment
id_tempo	int	100%	Represents a unique identifier for each time record, allowing for efficient indexing and retrieval of temporal data.
ano	int	100%	A unique identifier for each reference within the dataset, facilitating tracking and analysis of specific entries.
periodo	string	100%	Describes the specific time period (such as month or quarter) within the year, crucial for understanding seasonal trends and patterns.

5.2 CATÁLOGO DA DIM_ORGÃO

Campo	Tipo	Descrição	Origem/Domínio
id_orgao	INT	Identificador do órgão.	Gerado na camada Gold.
codigo_orgao	STRING	Código utilizado para identificação do órgão.	26291 para CAPES e 26000 para MEC.
nome_orgao	STRING	Nome ou sigla do órgão analisado.	CAPES ou MEC.
tipo_orgao	STRING	Classificação institucional do órgão.	Fundação ou Ministério.

Column	Type	Popularity	Comment
id_orgao	int		Unique identifier for each organization in the dataset, utilized for referencing purposes.
codigo_orgao	string		The code assigned to the organization, often used for internal identification and categorization.
nome_orgao	string		The name of the organization, which describes its identity and is used for display purposes.
tipo_orgao	string		The type of organization, indicating its classification or functional category within the broader context.

5.3 CATÁLOGO DA DIM_REGIAO

Campo	Tipo	Descrição	Origem/Domínio
id_regiao	INT	Identificador da região.	Gerado na camada Gold.
nome_regiao	STRING	Região brasileira associada à concessão das bolsas.	Norte, Nordeste, Centro-Oeste, Sudeste ou Sul.

Column	Type	Popularity	Comment
id_regiao	int		A unique identifier for each region, facilitating data analysis and ensuring distinct categorization of regions.
nome_regiao	string		The name of the region in which the educational institution operates, providing insight into regional distribution.

5.4 CATÁLOGO DA FATO_ORCAMENTO

Campo	Tipo	Descrição	Origem/Domínio
id_tempo	INT	Identificador do período de referência.	Chave relacionada à dim_tempo.
id_orgao	INT	Identificador do órgão.	Chave relacionada à dim_orgao.
dotacao_inicial	DECIMAL(18,2)	Valor da dotação orçamentária inicial.	Dados orçamentários da CAPES/MEC.
dotacao_atual	DECIMAL(18,2)	Valor atualizado da dotação orçamentária.	Dados orçamentários da CAPES/MEC.
empenhado	DECIMAL(18,2)	Valor das despesas empenhadas.	Dados orçamentários da CAPES/MEC.
liquidado	DECIMAL(18,2)	Valor das despesas liquidadas.	Dados orçamentários da CAPES/MEC.
pago	DECIMAL(18,2)	Valor das despesas pagas.	Dados orçamentários da CAPES/MEC.

Column	Type	Popularity	Comment
id_tempo	int		Represents the time identifier for budget allocations, allowing tracking across different fiscal periods.
id_orgao	int		Serves as the organization identifier, linking budget allocations to specific government bodies or departments.
dotacao_inicial	decimal(18,2)		Denotes the initial budget allocation at the start of the fiscal period.
dotacao_atual	decimal(18,2)		Shows the current budget allocation, which may have been adjusted from the initial amount.
empenhado	decimal(18,2)		Represents the amount of the budget that has been committed to obligations but not yet spent.
liquidado	decimal(18,2)		Indicates the total amount of the budget that has been processed and cleared for payment.
pago	decimal(18,2)		Reflects the total amount that has been disbursed from the budget as actual payments made.

A combinação entre `id_tempo` e `id_orgao` identifica cada registro da `fato_orcamento`, uma vez que a granularidade da tabela corresponde a um órgão em determinado ano.

5.5 CATÁLOGO DA FATO_BOLSAS

Campo	Tipo	Descrição	Origem/Domínio
<code>id_tempo</code>	INT	Identificador do período de referência.	Chave relacionada à <code>dim_tempo</code> .
<code>id_regiao</code>	INT	Identificador da região.	Chave relacionada à <code>dim_regiao</code> .
<code>quantidade_bolsas</code>	BIGINT	Quantidade total de bolsas concedidas.	Soma das bolsas por ano e região.

Filter columns...			
Column	Type	Popularity	Comment
<code>id_tempo</code>	int	...	Represents the time period associated with the data entry, typically used for analyzing trends over different time frames.
<code>id_regiao</code>	int	...	Identifies the geographical region relevant to the data, which is critical for regional analysis and reporting.
<code>quantidade_bolsas</code>	bigint	...	Indicates the total number of scholarships available in the specified region and time period, useful for assessing funding and resource allocation.

A combinação entre `id_tempo` e `id_regiao` identifica cada registro da `fato_bolsas`, cuja granularidade corresponde à quantidade de bolsas concedidas em determinada região e ano.

6. ANÁLISE DE DADOS

Após a construção e validação da camada Gold, foram realizadas as consultas destinadas a responder às quatro perguntas definidas no início do trabalho. As análises utilizam as tabelas `fato` e `dimensão` construídas anteriormente, permitindo comparar a evolução do orçamento da CAPES e do

MEC e relacionar essas informações ao comportamento das bolsas concedidas pela CAPES entre 2013 e 2020. Os resultados são apresentados a seguir de acordo com cada pergunta de negócio. Para facilitar a interpretação dos valores orçamentários, os resultados monetários foram convertidos para bilhões de reais nas consultas analíticas.

6.1 EVOLUÇÃO DO ORÇAMENTO DA CAPES ENTRE 2013 E 2020

Q1 - Como a dotação e a execução orçamentária da CAPES evoluíram entre 2013 e 2020, especialmente na comparação entre os períodos anterior e posterior a 2016?

Para responder à primeira pergunta, foram analisados os valores anuais de dotação inicial, dotação atual, empenhado, liquidado e pago da CAPES entre 2013 e 2020. Os dados foram obtidos a partir da `fato_orcamento`, utilizando a `dim_orgao` para selecionar os registros da CAPES e a `dim_tempo` para identificar os respectivos anos. Inicialmente, foi observada a evolução anual dos valores orçamentários. Para facilitar a leitura e a comparação dos resultados, os valores foram apresentados em bilhões de reais.

```
%sql
-- Analisa a evolução anual do orçamento da CAPES entre 2013 e 2020.

SELECT
    t.ano,
    ROUND(f.dotacao_inicial / 1000000000, 2) AS dotacao_inicial_bi,
    ROUND(f.dotacao_atual / 1000000000, 2) AS dotacao_atual_bi,
    ROUND(f.empenhado / 1000000000, 2) AS empenhado_bi,
    ROUND(f.liquidado / 1000000000, 2) AS liquidado_bi,
    ROUND(f.pago / 1000000000, 2) AS pago_bi
FROM mvp.gold.fato_orcamento f

INNER JOIN mvp.gold.dim_tempo t
    ON f.id_tempo = t.id_tempo

INNER JOIN mvp.gold.dim_orgao o
    ON f.id_orgao = o.id_orgao

WHERE o.nome_orgao = 'CAPES'

ORDER BY t.ano;
```

> [See performance \(1\)](#)

	ano	.00 dotacao_inicial_bi	.00 dotacao_atual_bi	.00 empenhado_bi	.00 liquidado_bi	.00 pago_bi
1	2013	4.24	5.30	4.83	4.28	4.26
2	2014	5.08	6.07	5.58	5.42	5.40
3	2015	6.27	7.43	7.77	7.66	7.65
4	2016	5.29	5.90	5.71	5.06	5.06
5	2017	4.96	4.96	4.71	3.94	3.94
6	2018	3.98	3.84	3.86	3.35	3.33
7	2019	4.25	4.19	4.20	3.82	3.82
8	2020	2.84	3.55	3.53	3.04	3.03

Os resultados mostram crescimento dos valores orçamentários da CAPES entre 2013 e 2015, seguido por uma redução nos anos posteriores. A dotação inicial passou de R\$ 4,24 bilhões em 2013 para R\$ 6,27 bilhões em 2015, maior valor observado na série analisada. Em 2016, esse valor foi reduzido para R\$ 5,29 bilhões e, apesar de uma pequena recuperação em 2019, chegou a R\$ 2,84 bilhões em 2020.

Comportamento semelhante pode ser observado nos valores de execução. O valor pago, por exemplo, passou de R\$ 7,65 bilhões em 2015 para R\$ 5,06 bilhões em 2016 e alcançou R\$ 3,03 bilhões em 2020. Dessa forma, os dados indicam uma redução tanto nos valores orçamentários quanto nos valores executados pela CAPES ao longo da segunda metade do período analisado.

<pre> %sql -- Compara as médias orçamentárias da CAPES entre 2013-2016 e 2017-2020. SELECT t.periodo, ROUND(AVG(f.dotacao_inicial) / 1000000000, 2) AS media_dotacao_inicial_bi, ROUND(AVG(f.dotacao_atual) / 1000000000, 2) AS media_dotacao_atual_bi, ROUND(AVG(f.empenhado) / 1000000000, 2) AS media_empenhado_bi, ROUND(AVG(f.liquidado) / 1000000000, 2) AS media_liquidado_bi, ROUND(AVG(f.pago) / 1000000000, 2) AS media_pago_bi FROM mvp.gold.fato_orcamento f INNER JOIN mvp.gold.dim_tempo t ON f.id_tempo = t.id_tempo INNER JOIN mvp.gold.dim_orgao o ON f.id_orgao = o.id_orgao WHERE o.nome_orgao = 'CAPES' GROUP BY t.periodo ORDER BY t.periodo; </pre>						
See performance (1)						
Table	+					
	periodo	.00 media_dotacao_inicial_bi	.00 media_dotacao_atual_bi	.00 media_empenhado_bi	.00 media_liquidado_bi	.00 media_pago_bi
1	2013-2016	5.22	6.18	5.97	5.61	5.59
2	2017-2020	4.01	4.14	4.07	3.54	3.53

A comparação entre os dois períodos reforça essa diferença. A média da dotação inicial passou de R\$ 5,22 bilhões entre 2013 e 2016 para R\$ 4,01 bilhões entre 2017 e 2020. A redução também aparece nas demais medidas, com destaque para o valor médio pago, que passou de R\$ 5,59 bilhões para R\$ 3,53 bilhões. Portanto, para a primeira pergunta de negócio, os resultados mostram que o período de 2017 a 2020 apresentou valores médios de dotação e execução inferiores aos observados entre 2013 e 2016. Essa comparação descreve a mudança observada nos dados ao redor do recorte temporal adotado no trabalho, **sem estabelecer, isoladamente, uma relação causal entre a mudança orçamentária e a EC nº 95/2016.**

6.2 COMPARAÇÃO ENTRE OS ORÇAMENTOS DA CAPES E DO MEC

Q2 - As alterações observadas no orçamento da CAPES acompanharam o comportamento do orçamento do MEC ou a CAPES apresentou uma dinâmica distinta entre 2013 e 2020?

Para responder à segunda pergunta, foi realizada uma comparação entre a evolução anual da dotação inicial da CAPES e do MEC entre 2013 e 2020. Para

isso, foram utilizados os registros da fato_orcamento, relacionando-os às dimensões dim_tempo e dim_orgao. Além dos valores anuais, foi calculada a variação percentual em relação ao ano anterior para identificar se os dois órgãos apresentaram comportamentos semelhantes ao longo do período.

```
%sql

-- Compara a evolução anual da dotação inicial da CAPES e do MEC.

WITH orcamento AS (
  SELECT
    t.ano,
    o.nome_orgao,
    f.dotacao_inicial
  FROM mvp.gold.fato_orcamento f

  INNER JOIN mvp.gold.dim_tempo t
    ON f.id_tempo = t.id_tempo

  INNER JOIN mvp.gold.dim_orgao o
    ON f.id_orgao = o.id_orgao
),
```

```
comparacao AS (
  SELECT
    ano,

    MAX(CASE
      WHEN nome_orgao = 'CAPES'
      THEN dotacao_inicial
    END) AS capes_dotacao,

    MAX(CASE
      WHEN nome_orgao = 'MEC'
      THEN dotacao_inicial
    END) AS mec_dotacao

  FROM orcamento
  GROUP BY ano
)
```

```
SELECT
    ano,

    ROUND(capes_dotacao / 100000000, 2)
    AS capes_dotacao_bi,

    ROUND(
        (capes_dotacao /
        LAG(capes_dotacao) OVER (ORDER BY ano) - 1) * 100,
        2
    ) AS capes_variacao_pct,

    ROUND(mec_dotacao / 100000000, 2)
    AS mec_dotacao_bi,

    ROUND(
        (mec_dotacao /
        LAG(mec_dotacao) OVER (ORDER BY ano) - 1) * 100,
        2
    ) AS mec_variacao_pct

FROM comparacao

ORDER BY ano;
```

	ano	.00 capes_dotacao_bi	.00 capes_variacao_pct	.00 mec_dotacao_bi	.00 mec_variacao_pct
1	2013	4.24	null	81.29	null
2	2014	5.08	19.67	94.49	16.24
3	2015	6.27	23.50	103.36	9.39
4	2016	5.29	-15.59	99.79	-3.46
5	2017	4.96	-6.27	107.52	7.74
6	2018	3.98	-19.85	107.55	0.03
7	2019	4.25	6.96	122.95	14.33
8	2020	2.84	-33.12	103.11	-16.13

Os resultados mostram que CAPES e MEC apresentaram alguns movimentos semelhantes no início do período. Entre 2013 e 2015, a dotação inicial cresceu nos dois casos, enquanto em 2016 ambos apresentaram redução em relação ao ano anterior. Entretanto, a partir de 2017, as trajetórias passaram a apresentar diferenças mais evidentes.

Em 2017, enquanto a dotação inicial da CAPES apresentou redução de 6,27%, o MEC registrou crescimento de 7,74%. Em 2018, a CAPES apresentou nova redução, de 19,85%, enquanto o orçamento do MEC permaneceu praticamente estável, com variação de 0,03%. Em 2019, ambos apresentaram crescimento, embora em proporções diferentes. Já em 2020, os dois apresentaram redução, sendo a queda da CAPES de 33,12%, superior aos 16,13% observados no MEC.

```
%sql

-- Compara a variação da dotação inicial da CAPES e do MEC entre 2016 e 2020.

WITH valores AS (
  SELECT
    t.ano,
    o.nome_orgao,
    f.dotacao_inicial
  FROM mvp.gold.fato_orcamento f

  INNER JOIN mvp.gold.dim_tempo t
    ON f.id_tempo = t.id_tempo

  INNER JOIN mvp.gold.dim_orgao o
    ON f.id_orgao = o.id_orgao

  WHERE t.ano IN (2016, 2020)
),
```

```
comparacao AS (
  SELECT
    nome_orgao,

    MAX(CASE WHEN ano = 2016
      THEN dotacao_inicial END) AS valor_2016,

    MAX(CASE WHEN ano = 2020
      THEN dotacao_inicial END) AS valor_2020

  FROM valores

  GROUP BY nome_orgao
)

SELECT
  nome_orgao,

  ROUND(valor_2016 / 1000000000, 2) AS dotacao_2016_bi,
  ROUND(valor_2020 / 1000000000, 2) AS dotacao_2020_bi,

  ROUND(
    (valor_2020 / valor_2016 - 1) * 100,
    2
  ) AS variacao_2016_2020_pct

FROM comparacao

ORDER BY nome_orgao;
```

> [See performance \(1\)](#)

	nome_orgao	.00 dotacao_2016_bi	.00 dotacao_2020_bi	.00 variacao_2016_2020_pct
1	CAPES	5.29	2.84	-46.26
2	MEC	99.79	103.11	3.33

A comparação entre 2016 e 2020 evidencia a diferença entre as trajetórias. Nesse intervalo, a dotação inicial da CAPES passou de R\$ 5,29 bilhões para R\$ 2,84 bilhões, correspondendo a uma redução de 46,26%. No

MEC, a dotação passou de R\$ 99,79 bilhões para R\$ 103,11 bilhões, representando crescimento de 3,33%.

Dessa forma, embora CAPES e MEC tenham apresentado movimentos semelhantes em alguns anos, **a CAPES apresentou uma dinâmica distinta no período analisado, principalmente após 2016**. A redução observada na CAPES foi mais acentuada e não acompanhou integralmente o comportamento do orçamento total do MEC.

6.3 PARTICIPAÇÃO DA CAPES NO ORÇAMENTO DO MEC

Q3 - Como evoluiu a participação do orçamento da CAPES em relação ao orçamento do MEC entre 2013 e 2020?

Para responder à terceira pergunta, foi calculada a participação percentual da dotação inicial da CAPES em relação à dotação inicial total do MEC em cada ano entre 2013 e 2020. Para isso, foram utilizados os valores disponíveis na `fato_orcamento`, relacionando os registros da CAPES e do MEC por meio da `dim_tempo` e da `dim_orgao`.

O cálculo foi realizado dividindo a dotação inicial da CAPES pela dotação inicial do MEC e multiplicando o resultado por 100. Dessa forma, foi possível observar quanto o orçamento da CAPES representou, percentualmente, do orçamento do MEC em cada ano analisado.

```
%sql
-- Calcula a participação da dotação inicial da CAPES em relação à dotação inicial total do MEC.
WITH orcamento AS (
  SELECT
    t.ano,
    o.nome_orgao,
    f.dotacao_inicial
  FROM mvp.gold.fato_orcamento f
  INNER JOIN mvp.gold.dim_tempo t
    ON f.id_tempo = t.id_tempo
  INNER JOIN mvp.gold.dim_orgao o
    ON f.id_orgao = o.id_orgao
),
```

<pre> valores AS (SELECT ano, MAX(CASE WHEN nome_orgao = 'CAPES' THEN dotacao_inicial END) AS capes_dotacao, MAX(CASE WHEN nome_orgao = 'MEC' THEN dotacao_inicial END) AS mec_dotacao FROM orcamento GROUP BY ano) SELECT ano, ROUND((capes_dotacao / mec_dotacao) * 100, 2) AS participacao_capes_pct FROM valores ORDER BY ano; </pre>		
See performance (1)		
Table		
	ano	.00 participacao_capes_pct
1	2013	5.22
2	2014	5.37
3	2015	6.06
4	2016	5.30
5	2017	4.61
6	2018	3.70
7	2019	3.46
8	2020	2.76

Os resultados mostram que a participação da CAPES no orçamento do MEC apresentou crescimento entre 2013 e 2015, passando de 5,22% para 6,06%. A partir de 2016, entretanto, observa-se uma trajetória de redução contínua. A participação passou para 5,30% em 2016, 4,61% em 2017, 3,70% em 2018, 3,46% em 2019 e atingiu 2,76% em 2020.

O menor percentual da série foi, portanto, observado em 2020. Esse comportamento complementa a comparação realizada na pergunta anterior, indicando que a redução do orçamento da CAPES não correspondeu apenas às alterações do orçamento total do MEC, mas também resultou em uma menor participação relativa da CAPES dentro do orçamento analisado.

%sql

-- Compara a participação média da CAPES no orçamento do MEC entre 2013-2016 e 2017-2020.

```
WITH participacao AS (  
    SELECT  
        t.periodo,  
        t.ano,  
  
        MAX(CASE  
            WHEN o.nome_orgao = 'CAPES'  
            THEN f.dotacao_inicial  
        END) AS capes_dotacao,  
  
        MAX(CASE  
            WHEN o.nome_orgao = 'MEC'  
            THEN f.dotacao_inicial  
        END) AS mec_dotacao  
  
    FROM mvp.gold.fato_orcamento f  
  
    INNER JOIN mvp.gold.dim_tempo t  
        ON f.id_tempo = t.id_tempo  
  
    INNER JOIN mvp.gold.dim_orgao o  
        ON f.id_orgao = o.id_orgao  
  
    GROUP BY  
        t.periodo,  
        t.ano  
)
```

```
SELECT  
    periodo,  
  
    ROUND(  
        AVG((capes_dotacao / mec_dotacao) * 100),  
        2  
    ) AS media_participacao_capes_pct  
  
FROM participacao  
  
GROUP BY periodo  
  
ORDER BY periodo;  
> See performance \(1\)
```

Table +

	periodo	.00 media_participacao_capes_pct
1	2013-2016	5.49
2	2017-2020	3.63

A comparação entre os períodos reforça essa mudança. Entre 2013 e 2016, a participação média da CAPES na dotação inicial do MEC foi de 5,49%. Entre 2017 e 2020, essa média caiu para 3,63%, uma diferença de 1,86 ponto percentual.

Dessa forma, os resultados respondem à terceira pergunta ao mostrar que **a participação relativa da CAPES no orçamento do MEC diminuiu no**

período analisado, especialmente a partir de 2016, alcançando em 2020 o menor percentual da série.

6.4 Evolução e distribuição das bolsas concedidas pela CAPES

Q4 - As alterações observadas no orçamento da CAPES foram acompanhadas por mudanças na quantidade e na distribuição das bolsas concedidas pela instituição?

Para responder à quarta pergunta, foi analisada inicialmente a evolução anual da quantidade de bolsas concedidas pela CAPES entre 2013 e 2020. Para isso, foram utilizados os dados da fato_bolsas relacionados à dim_tempo. Além dos valores anuais, foi calculada a variação percentual em relação ao ano anterior, permitindo observar as alterações ocorridas ao longo do período.

```
%sql

-- Analisa a evolução anual da quantidade de bolsas concedidas.
SELECT
    t.ano,
    SUM(f.quantidade_bolsas) AS total_bolsas,

    ROUND(
        (
            SUM(f.quantidade_bolsas) /
            LAG(SUM(f.quantidade_bolsas))
              OVER (ORDER BY t.ano) - 1
        ) * 100,
        2
    ) AS variacao_anual_pct

FROM mvp.gold.fato_bolsas f

INNER JOIN mvp.gold.dim_tempo t
    ON f.id_tempo = t.id_tempo

GROUP BY t.ano
ORDER BY t.ano;
```

> [See performance \(1\)](#)

	1.º ano	1.º total_bolsas	1.2 variacao_anual_pct
1	2013	85092	null
2	2014	105791	24.33
3	2015	105450	-0.32
4	2016	100433	-4.76
5	2017	101373	0.94
6	2018	101228	-0.14
7	2019	95290	-5.87
8	2020	95116	-0.18

Os resultados mostram um crescimento expressivo na quantidade de bolsas entre 2013 e 2014, quando o total passou de 85.092 para 105.791, representando aumento de 24,33%. A partir de 2015, entretanto, não se observa uma trajetória de crescimento contínuo. O total permaneceu próximo de 100 mil bolsas até 2018 e apresentou redução mais acentuada em 2019, chegando a 95.116 bolsas em 2020.

Apesar das reduções orçamentárias identificadas nas análises anteriores, a quantidade de bolsas não apresentou queda de magnitude semelhante. Em 2016 foram registradas 100.433 bolsas, enquanto em 2020 foram registradas 95.116, indicando uma redução relativamente menor no número de concessões durante esse intervalo.

Além da quantidade total, foi analisada a distribuição das bolsas entre as cinco regiões brasileiras. Para isso, a fato_bolsas foi relacionada à dim_regiao, sendo calculada a participação média de cada região no total de bolsas nos períodos de 2013–2016 e 2017–2020.

```
%sql

-- Compara a participação regional das bolsas entre 2013-2016 e 2017-2020.
WITH bolsas_regiao AS (
  SELECT
    t.ano,
    t.periodo,
    r.nome_regiao AS regiao,
    f.quantidade_bolsas,

    SUM(f.quantidade_bolsas)
      OVER (PARTITION BY t.ano) AS total_ano

  FROM mvp.gold.fato_bolsas f

  INNER JOIN mvp.gold.dim_tempo t
    ON f.id_tempo = t.id_tempo

  INNER JOIN mvp.gold.dim_regiao r
    ON f.id_regiao = r.id_regiao
),
```

```

participacao AS (
  SELECT
    periodo,
    ano,
    regioao,
    (quantidade_bolsas / total_ano) * 100
      AS participacao_pct
  FROM bolsas_regiao
)
SELECT
  regioao,

  ROUND(
    AVG(CASE
      WHEN periodo = '2013-2016'
      THEN participacao_pct
    END),
    2
  ) AS media_2013_2016_pct,

  ROUND(
    AVG(CASE
      WHEN periodo = '2017-2020'
      THEN participacao_pct
    END),
    2
  ) AS media_2017_2020_pct,

```

```

    ROUND(
      AVG(CASE
        WHEN periodo = '2017-2020'
        THEN participacao_pct
      END)
      -
      AVG(CASE
        WHEN periodo = '2013-2016'
        THEN participacao_pct
      END),
      2
    ) AS variacao_pontos_percentuais
  FROM participacao
  GROUP BY regioao
  ORDER BY media_2017_2020_pct DESC;

```

> [See performance \(1\)](#)

	regiao	1.2 media_2013_2016_pct	1.2 media_2017_2020_pct	1.2 variacao_pontos_percentuais
1	SUDESTE	46.98	47.5	0.52
2	SUL	22.95	23.12	0.17
3	NORDESTE	18.25	17.73	-0.52
4	CENTRO-OESTE	7.55	7.08	-0.47
5	NORTE	4.27	4.58	0.31

A distribuição regional apresentou poucas alterações entre os dois períodos. O Sudeste permaneceu como a região com maior participação, passando de 46,98% para 47,50% das bolsas. O Sul passou de 22,95% para 23,12%, enquanto o Norte passou de 4,27% para 4,58%.

O Nordeste apresentou redução de 18,25% para 17,73%, e o Centro-Oeste passou de 7,55% para 7,08%. Em todos os casos, as diferenças entre os dois períodos ficaram abaixo de um ponto percentual, indicando relativa estabilidade na distribuição regional das bolsas.

Dessa forma, os resultados indicam que as alterações observadas no orçamento da CAPES foram acompanhadas por algumas mudanças na quantidade de bolsas, mas não na mesma magnitude das alterações orçamentárias. A distribuição regional, por sua vez, permaneceu relativamente estável, sem mudanças expressivas na participação das cinco regiões entre os períodos analisados. Os resultados permitem identificar a coexistência dessas trajetórias no período estudado, mas não são suficientes, isoladamente, para estabelecer uma relação causal entre as alterações orçamentárias e o comportamento das concessões de bolsas.

7. CONSIDERAÇÕES FINAIS

O presente trabalho teve como objetivo desenvolver um pipeline de dados para organizar e analisar informações relacionadas ao orçamento da CAPES, ao orçamento do MEC e às bolsas concedidas pela CAPES entre 2013 e 2020. A partir da construção das camadas Bronze, Silver e Gold, foi possível integrar diferentes fontes de dados, realizar tratamentos de qualidade e estruturar um modelo de dados voltado às perguntas definidas no início do projeto.

Os resultados mostraram uma mudança na trajetória dos valores orçamentários da CAPES ao longo do período analisado. Após o crescimento observado entre 2013 e 2015, os valores apresentaram redução nos anos seguintes. Na comparação entre os períodos, a média da dotação inicial passou de R\$ 5,22 bilhões entre 2013 e 2016 para R\$ 4,01 bilhões entre 2017 e 2020. O valor médio pago também apresentou redução, passando de R\$ 5,59 bilhões para R\$ 3,53 bilhões.

A comparação com o MEC mostrou que essa trajetória não acompanhou de maneira uniforme o comportamento do orçamento total do Ministério. Entre 2016 e 2020, enquanto a dotação inicial da CAPES apresentou redução de 46,26%, a

dotação inicial do MEC apresentou crescimento de 3,33%. Essa diferença também foi observada na participação relativa da CAPES no orçamento do MEC, cuja média passou de 5,49% entre 2013 e 2016 para 3,63% entre 2017 e 2020.

Em relação às bolsas, foram observadas oscilações na quantidade de concessões ao longo dos anos, porém sem uma redução de magnitude semelhante àquela observada nos valores orçamentários. A distribuição regional também permaneceu relativamente estável, com diferenças inferiores a um ponto percentual na participação média das regiões entre os dois períodos analisados.

Dessa forma, o projeto permitiu identificar mudanças relevantes no comportamento das variáveis analisadas e demonstrou a aplicação de um pipeline de dados na integração, tratamento, modelagem e análise de diferentes bases públicas. Os resultados apresentados possuem caráter descritivo e não permitem, isoladamente, estabelecer uma relação causal entre as alterações observadas e a Emenda Constitucional nº 95/2016, utilizada neste trabalho como marco temporal para a comparação dos períodos.

8. AUTOAVALIAÇÃO

Na minha graduação de economia, enquanto elaborava **minha monografia** sobre o CT&I no Brasil, e seus impactos, eu me deparei com um grande impasse. Enquanto escrevia sobre o tema, e fazia as pesquisas de quais bibliografias usaria como referência, encontrei um gráfico muito interessante. O gráfico basicamente refletia o investimento em CT&I no Brasil, analisado pelos orçamentos do FNDCT, CAPES e CNPq. No entanto, pela data de divulgação, ele já estava um pouco desatualizado.

Minha intenção era ter um gráfico mais atual possível, e por isso, tentei elaborar o meu. Mas acredito que acabei falhando por falta de conhecimentos de conceitos muito específicos. Por não conseguir elaborar um gráfico atual, tive que usar o que já estava posto na bibliografia. Senti que isso foi um grande limitador no meu trabalho, e por isso, garanti que tentaria me aprofundar na área após a graduação.

Assim, para o MVP dessa disciplina, tentei fazer aquilo que tive grande dificuldade, mas em menor escala. Tentei focar minha análise **na CAPES**, que era justamente uma das instituições, para tentar verificar o orçamento de forma individual, e tive dados muito interessantes.

Para além disso, estou muito feliz que consegui realizar esse passo. Por mais que eu tenha tido um pouco de dificuldade com o código (e por isso recorri à IA em alguns momentos), sinto que consegui chegar aonde queria. Não montei um gráfico sobre as três instituições, mas sinto que essa pequena etapa já abriu um leque de oportunidades. Fiquei bastante satisfeito com tudo que aprendi e apliquei, e principalmente com o resultado.

Com isso, para meus próximos trabalhos na área de dados, pretendo ampliar a análise para as três instituições (FNDCT, CAPES e CNPq) aprofundando temas que já fazem parte dos meus interesses acadêmicos e utilizando como base os conhecimentos adquiridos ao longo do curso. Como projeto futuro, pretendo desenvolver um pipeline que integre os dados dessas três instituições e permita gerar, de forma automatizada e atualizada, um gráfico sobre o investimento público em CT&I a partir de seus respectivos orçamentos.

No mais, agradeço muito aos orientadores e professores, pela atenção e cuidado na condução da disciplina. Obrigado!